Approches d'intelligence artificielle explicable pour les Réseaux de neurones

Chouati Linda, Corentin Attia

Université Claude Bernard, Lyon 1

Abstract

L'explicabilité des modèles d'apprentissage profond est essentielle pour comprendre leurs décisions et évaluer leur fiabilité. Cet article compare donc les approches post-hoc (LIME, SHAP, Grad-CAM) et intrinsèquement explicables (Neural Additive Models, Neural-Backed Decision Trees) appliquées aux réseaux de neurones. Nous évaluons leur applicabilité sur un modèle de classification entraîné sur des données tabulaires dans un cadre éducatif. Nos résultats ne permettent pas de tirer de conclusions généralisables quant à la supériorité d'une approche sur l'autre, soulignant ainsi les défis liés à l'évaluation de l'explicabilité. Ce travail met en évidence la nécessité de mieux structurer les critères d'évaluation des méthodes XAI et d'explorer des approches hybrides conciliant interprétabilité et performance.

Introduction

Les réseaux de neurones artificiels se sont imposés comme l'une des avancées majeures de l'intelligence artificielle (IA). En effet, ils ont une immense capacité à traiter d'énorme volumes de données et à obtenir de bonnes performances dans divers domaines (par ex., reconnaissance d'images [1], traitement du langage [2] ou prédiction de séries temporelles [3]). Toutefois, ces modèles, souvent décrits comme des « boîtes noires », soulèvent un problème fondamental : il est difficile de comprendre et de justifier leurs décisions, et cela même pour des experts. Cela pose notamment des problèmes lorsqu'ils interviennent dans des domaines sensibles où les enjeux éthiques, de responsabilité et de confiance sont primordiaux [4].

Afin de pallier ce manque de transparence dans les modèles d'apprentissage automatique, l'intelligence artificielle explicable (XAI) s'est imposée comme un champ de recherche central. L'objectif est de développer des méthodes capables de fournir des interprétations claires et compréhensibles du fonctionnement des modèles notamment dont les réseaux de neurones. Cette exigence d'explicabilité est aussi encouragée par les avancées réglementaires, notamment le RGPD [5] (Règlement Général sur la Protection des Données) et l'AI Act en Europe [6], qui imposent de plus en plus la nécessité de justifier les décisions automatisées dans certains secteurs. Bien plus, l'explicabilité peut aider ingénieurs et chercheurs à repérer des biais ou des erreurs, renforçant ainsi la fiabilité globale des systèmes.

Bien que l'intelligence artificielle explicable (XAI) fasse l'objet de nombreux travaux [7, 8], l'application de ces méthodes à des données tabulaires et, en particulier, au domaine éducatif, reste moins développée [9]. Plusieurs études soulignent l'importance d'offrir aux enseignants et responsables pédagogiques des outils explicables, mais la recherche dans ce champ demeure encore embryonnaire [10].

Dans cet article, nous proposons donc un aperçu des approches qui rendent les réseaux de neurones plus interprétables, en mettant l'accent sur la comparaison entre méthodes post-hoc, appliquées après l'entraînement du modèle, et approches intrinsèquement explicables, conçues pour être interprétables dès leur architecture. Nous illustrons différents de ces outils au moyen d'un cas pratique sur données tabulaires liées à la performance académique d'étudiants. Nous étudions dans quelle mesure ces

méthodes de XAI peuvent rendre le fonctionnement d'un réseau de neurones plus compréhensible et aider des utilisateurs non experts à mieux saisir et interpréter les prédictions du modèle. D'ailleurs dans ce sens, une implémentation d'une interface afin de pouvoir interpréter un réseau de neurone a été réalisé dans le cadre de la rédaction de cet article scientifique. Il s'agit pour nous d'une première étape visant à rendre les principes fondamentaux de l'intelligence artificielle explicable accessibles à un large public, y compris les utilisateurs non experts.

État de l'art

Distinction entre hiérarchisation des méthodes de XAI

Dans la littérature, la frontière entre méthodes post-hoc et méthodes intrinsèquement explicables constitue l'un des classements les plus courants, mais elle n'est pas la seule manière de segmenter l'intelligence artificielle explicable [7,2]. En effet, plusieurs scientifiques proposent également de distinguer des approches locales, centrées sur une prédiction donnée, et globales, qui cherchent à rendre compte du fonctionnement général d'un modèle, ou encore model-agnostic et model-specific, selon qu'elles nécessitent ou non un accès détaillé à l'architecture interne. De plus, certains travaux considèrent des méthodes dites neuro-symboliques ou faisant appel à des exemples contrefactuels**,** illustrant la diversité des propositions au sein du champ XAI [13].

L'objectif commun de toutes ces catégories est de répondre à des besoins d'interprétation pouvant varier selon le domaine d'application, la complexité des données. La distinction post-hoc / intrinsèquement explicable reste toutefois un repère essentiel pour comprendre si l'explication est conçue dès la phase de modélisation ou bien ajoutée une fois le réseau de neurones entraîné. Bien plus, nous avons privilégié cette catégorisation car elle offre une vision claire et pragmatique de la manière dont l'explicabilité est abordée dans le développement des réseaux de neurones, tout en permettant d'orienter le choix de la méthode en fonction des besoins spécifiques en interprétabilité.

Panorama des approches post-hoc

Les méthodes post-hoc correspondent aux solutions mises en œuvre après l'entraînement des modèles afin de comprendre comment les résultats ont été obtenus, en analysant les poids des différentes variables et/ou en identifiant les schémas de décision adoptés.

LIME (Local Interpretable Model-Agnostic Explanations)

LIME, comme son nom l'indique, cherche à obtenir des explications locales à un modèle contrairement aux modèles globaux qui visent à comprendre le comportement général du modèle.

Développée par Ribeiro, Singh et Guestrin [15], LIME s'est imposée comme l'une des premières approches post-hoc à gagner en notoriété. Son principe consiste à construire, autour d'une prédiction ciblée, un modèle interprétable, tel qu'une régression linéaire qui approxime localement le comportement du réseau de neurones. Concrètement, LIME génère des instances « factices » en modifiant les données d'entrée, puis observe comment la prédiction varie. Cette méthode localise ainsi les variables les plus influentes dans la décision finale, offrant une explication précise pour un individu ou un cas donné. Cette approche locale facilite donc la compréhension du raisonnement du modèle pour un cas spécifique.

Toutefois, LIME présente plusieurs limites. D'une part, son caractère local fait que des explications pertinentes pour une instance peuvent ne pas être généralisables à l'ensemble du jeu de données. D'autre part, les variations artificielles qu'elle introduit dépendent de multiples paramètres (choix et nombre d'échantillons perturbés, distance de la perturbation, etc.), ce qui peut nuire à la stabilité et à la reproductibilité des explications. Par ailleurs, dans un problème multi-classes, la baisse de probabilité d'une classe ne se traduit pas nécessairement par la hausse des autres, rendant l'analyse plus complexe à interpréter. Ces facteurs ont conduit certains chercheurs à envisager des solutions plus globales ou plus

robustes pour pallier ces difficultés [12]. Ainsi, pour améliorer LIME et mieux gérer ses aléas, différentes pistes ont été explorées. Ribeiro et al. ont ainsi proposé les Anchors, qui fournit des règles if-then tenant lieu d'"ancrages" assurant une certaine précision pour chaque instance expliquée [22]. Par ailleurs, des approches hybrides mêlant LIME et des techniques d'explicabilité globale comme la sélection de features basée sur SHAP, cherchent à conjuguer la simplicité d'une explication locale à une vision plus cohérente à l'échelle du dataset.

SHAP (SHapley Additive exPlanations)

SHAP est issue de la théorie des valeurs de Shapley, un concept issu lui-même de la théorie des jeux coopératifs introduit en 1950 par Lloyd Shapley. À l'origine, les valeurs de Shapley servaient à attribuer équitablement la contribution d'un joueur au résultat final d'une partie. Aujourd'hui dans le monde de l'apprentissage, les valeurs de Shapley servent à attribuer à chaque caractéristique d'une donnée une valeur reflétant sa contribution à la prédiction du modèle.

Proposé par Lundberg et Lee [14] SHAP repose donc sur l'idée de tester toutes les combinaisons possibles de variables d'un modèle, pour analyser comment l'absence ou la présence de chaque caractéristique influence la prédiction. Autrement dit, pour chaque caractéristique (ou "joueur"), on évalue sa contribution marginale à la prédiction du modèle dans tous les sous-ensembles possibles de caractéristiques. Cela permet de déterminer de manière précise l'impact de chaque variable, indépendamment des autres, assurant ainsi une interprétation fidèle et précise.

Cette approche offre un cadre mathématique rigoureux**,** ce qui améliore la stabilité des interprétations par rapport à LIME, réputé plus sensible aux perturbations [15]. Cette approche fournit donc un score qui reflète combien chaque feature influe réellement sur la décision du modèle, de façon plus formellement justifiée que LIME.

Afin de mieux s'adapter à la diversité des architectures neuronales, plusieurs déclinaisons de SHAP ont été proposées, dont Deep SHAP, spécifiquement conçue pour les réseaux profonds [14]. Néanmoins, ce formalisme théorique a un coût de calcul potentiellement élevé car l'exploration d'un grand nombre de sous-ensembles de variables engendre une complexité combinatoire. Même si des optimisations tel que des approximations stochastiques ou des variantes exploitant la structure des couches du réseau, permettent de réduire la complexité, l'utilisation de SHAP demeure souvent plus lourde que celle de LIME.

Par ailleurs, SHAP s'applique avant tout à des données structurées (tabulaires, vecteurs de features) mais pour des tâches de vision par ordinateur ou de traitement du langage cela n'est pas possible. C'est pourquoi des extensions comme Gradient SHAP viennent exploiter les gradients internes pour générer des attributions [16] pour pallier cette limite, mais leur mise en œuvre peut se révéler moins directe que des méthodes visuelles tel que Grad-CAM.

Grad-CAM (Gradient-weighted Class Activation Mapping)

Grad-CAM s'adresse en priorité aux réseaux convolutionnels utilisés pour des tâches d'analyse d'images. C'est est une méthode qui propose une explication visuelle à une prédiction, contrairement à SHAP et LIME, en mettant en évidence les régions de l'image qui ont le plus influencé la décision du modèle. Proposée par Selvaraju et al. [17], cette méthode analyse les gradients des scores de sortie en fonction des activations des dernières couches convolutionnelles d'un réseau de neurones. Elle permet ainsi d'identifier les zones de l'image qui ont le plus influencé la prédiction du modèle. Ces informations sont ensuite utilisées pour créer une carte de chaleur superposée à l'image originale, mettant en évidence les régions les plus importantes.

D'un autre côté, Guided Grad-CAM est une amélioration de Grad-CAM qui combine les avantages de son prédécéceur et de Guided Backpropagation (GB). Alors que Grad-CAM capture des informations de haut niveau et produit une carte de chaleur floue indiquant les régions importantes de l'image, GB

permet de récupérer des détails plus fins en ne gardant que les gradients positifs lors de la rétropropagation grâce à la méthode de Guided Backpropagation.

Cependant, Grad-CAM et ses dérivés demeurent dédiés au traitement d'images**,** ne répondant pas forcément aux besoins d'autres domaines, comme les données tabulaires ou le texte.

LRP (Layer-wise Relevance Propagation)

Dans la lignée des approches basées sur le gradient, LRP est une méthode qui permet de visualiser les pixels ou caractéristiques les plus influentes dans une prédiction [18]. Cette technique est également applicable aux modèles de traitement du langage naturel (NLP), où elle met en évidence les mots ou groupes de mots exerçant une forte influence sur la décision finale. Cette technique retransmet l'importance de la prédiction en remontant à travers les couches du modèle pour attribuer à chaque pixel ou mot un score en fonction de son impact sur le résultat final. LRP suit donc un processus de rétropropagation des scores de contribution, couche par couche.

Contrairement à d'autres techniques d'interprétation par exemple comme SHAP, LRP propose une alternative plus rapide et moins exigeante en termes de calcul. En effet, en exploitant la structure du réseau neuronal, LRP permet de générer des explications en une seule passe arrière, ce qui réduit considérablement le coût computationnel [24]. De plus cette méthode est souvent plus rapide et plus adaptée à des scénarios où l'on a besoin de rétroactions réactives, comme en traitement du langage naturel ou en vision. Toutefois, contrairement à Grad-CAM, LRP dépend étroitement de la structure du réseau et nécessite un accès aux poids internes et aux activations. De plus, elle reste vulnérable aux perturbations adversariales qui peuvent modifier significativement les attributions. Pour pallier cette fragilité, certaines approches proposent de stabiliser les gradients locaux afin d'améliorer la robustesse des méthodes d'attribution. Joo et al. [23] montrent que l'ajout d'une régularisation combinant un critère L2 et une distance cosinus permet d'obtenir des explications plus cohérentes et résistantes aux manipulations adversariales.

En offrant donc une explication claire et efficace des décisions prises par le modèle, LRP est une méthode particulièrement adaptée pour des applications nécessitant des interprétations rapides et compréhensibles.

XRAI (Explainable Representations through AI)

Dans la même logique, XRAI quant à lui propose un raffinement de l'analyse visuelle en segmentant l'image en superpixels cohérents [19], plutôt que de s'en tenir à de simples heatmaps. En effet, c'est une méthode qui permet d'identifier et de visualiser les régions les plus pertinentes pour la décision d'un modèle. Donc, XRAI, en segmentant l'image en superpixels cohérents, facilite l'interprétation et la compréhension des décisions du modèle. Grâce à cette analyse par régions, la méthode identifie plus clairement les formes, contours et textures qui ont influencées la décision du modèle. Cela contribue non seulement à valider la fiabilité du système, mais aussi à détecter d'éventuels biais.

L'avantage de XRAI réside dans sa focalisation régionale, qui va au-delà de l'aspect global des méthodes comme Grad-CAM. Cependant, son efficacité dépend de la qualité de la segmentation en superpixels. En effet, toute imprécision dans le découpage initial peut conduire à des explications moins pertinentes. De plus, la méthode reste étroitement liée à un contexte d'analyse d'images, sans possibilité d'extension immédiate à d'autres types de données, comme du texte ou des données tabulaires. Pour améliorer XRAI, certaines pistes consistent à combiner l'algorithme avec des techniques de segmentation plus avancées comme des algorithmes multi-échelles ou à intégrer des mécanismes d'attention qui ajustent dynamiquement la taille et la forme des superpixels [20]. D'autres travaux proposent d'ajouter des retours d'utilisateurs pour corriger manuellement les régions segmentées, assurant ainsi une cohérence sémantique plus fine entre les superpixels et les objets réels [21].

Panorama des approches intrinsèques

Les modèles intrinsèquement explicables se distinguent des approches post-hoc en intégrant la capacité d'interprétation directement dans la conception du modèle. Plutôt que de recourir à des méthodes d'analyse appliquées après l'entraînement comme LIME, SHAP..., ces modèles sont construits de manière à rendre leur fonctionnement transparent dès leur développement. L'idée fondamentale est d'imposer dès la phase de conception des contraintes architecturales qui facilitent la compréhension du processus décisionnel. Cela se traduit par la création d'architectures où chaque couche ou composant du réseau contribue explicitement à la prise de décision, rendant ainsi possible l'audit et l'interprétation des résultats sans avoir besoin d'outils complémentaires une fois le modèle construit.

Cette démarche répond non seulement aux exigences réglementaires et aux attentes éthiques en termes de transparence, mais elle favorise également une meilleure confiance des utilisateurs. Des travaux récents insistent sur l'importance de développer des modèles dont l'explicabilité est intégrée, afin d'améliorer la robustesse, la traçabilité et la capacité à identifier et corriger d'éventuels biais [4].

Réseaux neuronaux à architecture explicable

Dans cette catégorie, l'objectif est de concevoir la structure même du réseau afin de faciliter l'interprétation de ses décisions, sans nécessairement générer automatiquement une explication complète pour chaque prédiction. Autrement dit, l'architecture est pensée pour être intrinsèquement compréhensible tout en maintenant un haut niveau de performance.

Une première stratégie consiste à segmenter le réseau en parties plus simples, appelées sous-modèles ou modules transparents, afin de clarifier le rôle de chaque composant dans le processus décisionnel. Plutôt que de considérer le réseau entier comme une « boîte noire », on cherche à diviser l'architecture en modules distincts qui se spécialisent dans l'extraction ou le traitement de caractéristiques spécifiques de l'entrée. Par exemple, une approche alternative repose sur le concept de "mixture of experts [12]. Dans ce type d'architecture, l'entrée est d'abord traitée par plusieurs experts, chacun étant spécialisé dans un aspect particulier (par exemple, la texture, la forme ou la couleur dans une image). Un mécanisme de gating combine ensuite les sorties de ces experts pour produire la prédiction finale. Les poids attribués par ce mécanisme indiquent clairement l'importance relative de chaque expert dans la décision, offrant ainsi une vision plus transparente du processus décisionnel. Cette segmentation modulaire permet de comprendre quelles parties du modèle sont responsables de l'extraction des informations pertinentes et facilite ainsi l'analyse de la logique interne du réseau.

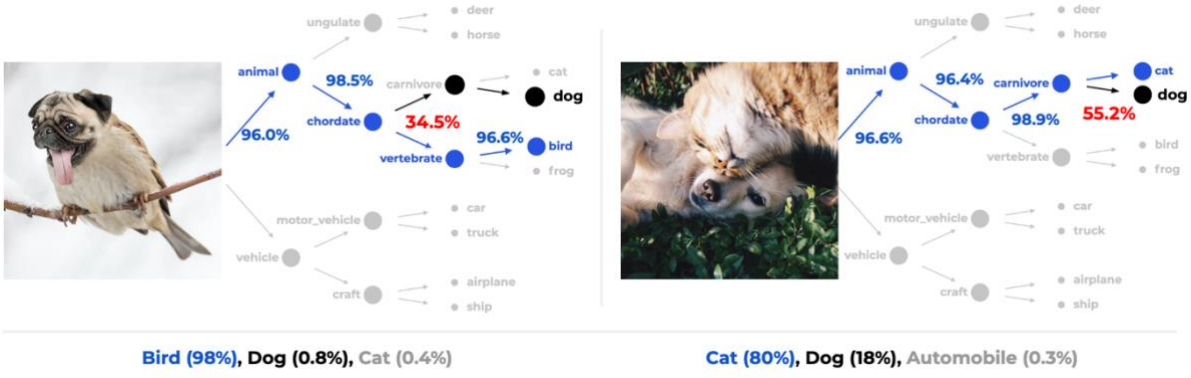


Figure 1 : Exemple d'application des Neural-Backed Decision Trees (NBDT) pour gérer des labels ambigus en classification d'images (extrait de [25])

Une autre approche consiste à hybrider le réseau avec un modèle intrinsèquement interprétable, tel qu'un arbre de décision. Dans les Neural-Backed Decision Trees (NBDT), la couche de sortie d'un réseau classique est remplacée ou complétée par un arbre hiérarchique qui décompose le processus décisionnel en plusieurs étapes [25]. Concrètement, le réseau produit non seulement une prédiction finale, mais fournit aussi une structure arborescente qui indique, de la racine jusqu'à la feuille, les décisions

successives menant à la classification, comme illustré sur la figure 1. Chaque nœud de cet arbre correspond à une décision ou à un concept spécifique, ce qui permet d'identifier clairement l'impact des caractéristiques de l'entrée sur la prédiction. Par exemple, dans une tâche de classification d'images, le modèle peut d'abord déterminer que l'image appartient à la catégorie « animal » puis, à un niveau plus fin, distinguer entre « chat » et « chien » en fonction des détails visibles dans l'image.

Une deuxième stratégie consiste à imposer des contraintes sur les poids et les activations du réseau pour améliorer sa lisibilité [26]. Par exemple, en appliquant une régularisation L1 – qui pénalise la somme des valeurs absolues des poids – le modèle est encouragé à devenir sparse, c'est-à-dire à réduire le nombre de connexions actives. Ainsi, seuls quelques neurones essentiels contribuent à la décision finale, ce qui facilite l'identification des caractéristiques clés qui influencent la prédiction. Cette approche est est présentée comme une méthode efficace pour la sélection de caractéristiques et la simplification des modèles.

Une autre stratégie pour améliorer l'interprétabilité d'un modèle consiste à introduire dans l'architecture une couche intermédiaire dédiée à la représentation de concepts explicites. Concrètement, le modèle est entraîné de manière que chaque neurone de cette couche représente un concept prédéfini et compréhensible par l'humain [27]. Par exemple, dans le cas d'une radiographie, certains neurones pourraient être associés à des caractéristiques telles que la forme ou la disposition des articulations. La prédiction finale du modèle est ensuite obtenue en combinant ces concepts avec des poids spécifiques, ce qui permet de retracer la décision en identifiant clairement l'importance relative de chaque concept. Les Concept Bottleneck Models illustrent cette approche en forçant le réseau à passer par une étape de prédiction intermédiaire où les concepts sont d'abord estimés, puis utilisés pour produire la prédiction finale. Cette démarche offre deux avantages majeurs. En effet, elle rend la logique du modèle plus transparente, car la décision finale est directement expliquée par des concepts clairement définis, et elle permet d'intervenir directement sur ces concepts pour corriger ou ajuster la prédiction. Ainsi, si un expert constate qu'un concept est mal évalué, par exemple, que la présence d'une anomalie est surévaluée, il peut modifier cette valeur pour observer l'impact sur la sortie du modèle, renforçant ainsi la confiance dans le système en rendant plus aisée la vérification de sa logique de décision.

En combinant ces stratégies, l'architecture du réseau est modifiée pour devenir intrinsèquement plus lisible, facilitant l'analyse couche par couche et renforçant la confiance des utilisateurs. Néanmoins, ces méthodes présentent souvent un compromis : en améliorant l'interprétabilité, on peut réduire la performance brute si les contraintes sont trop strictes. De plus, adapter ces techniques à l'ensemble des tâches de deep learning nécessite une calibration précise, car chaque domaine ou application peut exiger un ajustement spécifique des paramètres et des architectures. En définitive, si ces approches offrent des perspectives prometteuses pour rendre les modèles plus transparents, il reste essentiel de trouver l'équilibre optimal entre la performance et la capacité d'explication.

Réseaux neuronaux auto-explicatifs

Les réseaux neuronaux auto-explicatifs vont plus loin en intégrant dès l'architecture la génération automatique d'explications pour chaque prédiction. Contrairement aux modèles à architecture explicable, qui visent principalement à faciliter l'inspection de la logique interne du réseau, les réseaux auto-explicatifs produisent spontanément des justifications ou des scores de pertinence en même temps qu'ils génèrent leur sortie. Autrement dit, l'explication devient un sous-produit direct du calcul, plutôt qu'une analyse postérieure.

Concrètement, un tel réseau fournit simultanément la prédiction et divers signaux explicatifs, tels que des relevances, un texte décrivant les raisons de la décision ou encore des règles symboliques. Pour garantir que le modèle se comporte localement comme une fonction linéaire et que les explications restent stables sous de petites variations de l'entrée, une contrainte de régularisation est imposée. Cela force le réseau à produire des coefficients qui varient de manière douce, assurant ainsi des explications cohérentes et fidèles.

L'architecture d'un Self-Explaining Neural Networks (SENN) se base sur cette approche [28]. Il permet donc de générer directement, pour chaque instance, à la fois la prédiction et les scores locaux qui expliquent l'impact de chaque concept. Cela permet une interprétation immédiate des décisions du réseau, combinant explicabilité et performance prédictive.

Cette intégration native de l'explicabilité offre plusieurs avantages. En effet, l'utilisateur reçoit immédiatement la justification d'une décision sans recourir à un outil complémentaire, et les explications sont généralement plus stables face aux légères perturbations de l'entrée. Cela permet donc de renforcer ainsi la confiance et la traçabilité. Toutefois, la mise en œuvre de ces modèles demande une conception minutieuse ainsi qu'un réglage précis de la régularisation, afin d'éviter la génération d'explications plausibles mais déconnectées de la réalité interne du réseau. De plus, l'adaptation de ces stratégies à des données massives et hétérogènes, comme l'imagerie 3D ou des documents variés, peut nécessiter un effort d'ingénierie considérable. Malgré ces défis, les réseaux auto-explicatifs représentent un pas décisif vers des systèmes où la décision et l'explication sont intimement liées dès l'entraînement, répondant ainsi aux exigences de transparence dans des secteurs sensibles.

Réseaux neuronaux hybrides avec IA symbolique

Une autre perspective consiste à revenir aux méthodes symboliques. En effet, l'intelligence artificielle a d'abord été dominée par les approches symboliques, qui reposent sur la représentation explicite des connaissances et le raisonnement logique. Ces systèmes permettent une explication claire des décisions, mais souffrent d'un manque de flexibilité et de capacité d'apprentissage. À l'inverse, les réseaux neuronaux largement adoptés aujourd'hui, excellent en reconnaissance de motifs et en généralisation à partir de données massives mais leur fonctionnement reste opaque et difficilement interprétable.

Ainsi, la recherche en neuro-symbolique vise à combiner le raisonnement symbolique et l'apprentissage neuronal pour pallier les limites de chaque approche et améliorer l'explicabilité des modèles. Les systèmes hybrides exploitent la capacité des réseaux neuronaux à traiter de grandes quantités de données non structurées tout en intégrant des connaissances explicites sous forme de règles logiques pour guider le processus décisionnel.

L'explicabilité est donc possible en structurant l'apprentissage et en encadrant la prise de décision à l'aide de règles logiques ou de connaissances symboliques [29]. Cette approche permet de contraindre les activations neuronales en fonction de principes formels, garantissant ainsi une interprétabilité intrinsèque des décisions. Les Logically Constrained Neural Networks (LCNNs) en sont un exemple, imposant des règles logiques pour orienter le comportement du réseau [13].

Un autre axe d'amélioration de l'explicabilité repose sur la capacité de ces modèles à générer des explications compréhensibles. Certains systèmes hybrides produisent directement des justifications textuelles ou des règles symboliques expliquant leurs décisions. DeepProbLog, une extension neuronale du langage Prolog, associe apprentissage automatique et raisonnement logique pour fournir des raisonnements interprétables accompagnant ses prédictions [13].

Ces modèles présentent plusieurs avantages en matière d'explicabilité. L'intégration explicite de règles formelles permet une traçabilité des décisions, facilitant la validation des modèles. En encadrant l'apprentissage à l'aide de connaissances externes, ces approches réduisent également le risque de biais, assurant des décisions plus fiables et cohérentes. Toutefois, leur mise en œuvre pose encore des défis. La fusion entre modèles neuronaux et raisonnements symboliques demeure complexe, nécessitant des ajustements délicats entre représentation numérique et manipulation logique. De plus, le coût computationnel peut être très élevé. De plus, la fiabilité de ces systèmes dépend largement de la qualité des connaissances symboliques utilisées, une base de règles incomplète ou erronée peut induire des biais dans les décisions générées par le modèle.

Les modèles neuro-symboliques constituent donc une avancée majeure vers une IA explicable en combinant apprentissage statistique et raisonnement logique. Ils permettent de justifier les prédictions des réseaux neuronaux de manière plus formelle que les approches post-hoc et offrent une meilleure traçabilité des décisions. Cependant, leur mise en œuvre reste un défi et leur adoption à grande échelle nécessitera des avancées techniques.

Synthèse

L'approche de classification entre post-hoc et intrinsèquement explicable se justifie donc par la nécessité de distinguer le moment où l'explicabilité est intégrée.

Les méthodes post-hoc, telles qu'étudié plus haut, apportent des explications en analysant le comportement d'un modèle déjà entraîné. Elles permettent de mettre en évidence, pour des cas particuliers ou de manière globale, l'influence de chaque variable ou région d'une image sur la décision du modèle. Chacune de ces méthodes présente ses avantages et ses limites, notamment en termes de stabilité, de complexité computationnelle ou d'applicabilité à différents types de données.

L'approche intrinsèquement explicable permet quant à elle, à partir d'un seul et même processus, d'avoir à la fois une prédiction et une explication de cette prédiction. Cela a permet d'éliminer ainsi le besoin de recourir à une analyse postérieure où le fonctionnement interne du modèle est dévoilé. Cette démarche permet non seulement d'assurer une meilleure traçabilité et une plus grande robustesse, tout en facilitant l'intervention en cas de détection de biais ou d'anomalies.

Méthodologie

Afin de mieux comprendre l'impact des différentes techniques d'intelligence artificielle explicable sur des modèles de réseaux de neurones, nous avons décidé de construire un réseau de neurones multi-couches (MLP), un Neural Additive Model (NAM) et d'expérimenter quelques méthodes post-hoc adaptées aux données tabulaires. Bien que des études existent, une grande partie des travaux en XAI se concentre sur les images, ce qui nous a motivés à explorer son application aux données tabulaires dans un contexte éducatif.

Notre expérimentation cherche donc à évaluer si les méthodes XAI actuelles permettent réellement d'expliquer de façon claire et compréhensible les prédictions d'un modèle de réseau de neurones appliqué à des données tabulaires. Nous voulons aussi savoir si ces explications sont utilisables par des personnes non expertes, comme des enseignants ou des éducateurs, qui doivent comprendre les décisions du modèle sans nécessairement avoir de connaissances en intelligence artificielle.

Jeu de données utilisé

Pour cette étude, nous avons utilisé le jeu de données, xAPI-Edu-Data, de Kaggle souvent utilisé pour prédire la performance académique des étudiants. Celui-ci regroupe notamment des informations sur les comportements d'apprentissage, les résultats académiques et certaines données démographiques. La variable cible classe les étudiants en trois catégories de performance : Faible (L), Moyen (M) et Élevé (H). Nous avons donc choisi ce jeu de données car il permet d'évaluer comment les méthodes d'explicabilité peuvent aider à identifier les facteurs influençant la réussite des étudiants, un enjeu important pour l'éducation et les systèmes d'apprentissage basés sur l'IA.

Modèle choisi

Le modèle choisi est un réseau de neurones multi-couches (MLP - Multi-Layer Perceptron), permettant de classer les étudiants en trois catégories de performance soit Faible, Moyen et Élevé, afin par la suite d'y appliquer des méthodes post-hoc. Un MLP car il est particulièrement adapté aux données tabulaires, tout en conservant une architecture relativement simple et efficace pour notre tâche.

Notre modèle est structuré avec une couche d'entrée qui prend en compte toutes les variables du dataset, suivie de plusieurs couches cachées utilisant la fonction d'activation ReLU afin de capturer les interactions non linéaires entre les données. La couche de sortie applique une activation softmax, permettant d'assigner chaque étudiant à l'une des trois classes de performance académique.

Méthodes de XAI utilisées

Une fois notre modèle entraîné et évalué, nous avons appliqué différentes techniques d'explicabilité pour analyser les prédictions. Pour cela, nous avons implémenté des méthodes post-hoc, qui permettent d'expliquer un modèle après son entraînement, à savoir LIME, SHAP, DeepLIFT et Integrated Gradients, en utilisant les bibliothèques LIME, SHAP et Captum de PyTorch. En complément, nous avons testé des modèles intrinsèquement explicables tels que le Neural Additive Model (NAM) et un MLP peu profond. NAM a été implémenté sous forme d'un ensemble de sous-réseaux indépendants, où chaque sous-réseau apprend l'effet d'une seule variable sur la classification. Les contributions de chaque variable sont ensuite agrégées pour obtenir la prédiction finale.

Ainsi, en combinant ces approches, nous pouvons mieux juger la qualité et la cohérence des explications, ce qui sera analysé dans la section des résultats.

Résultats et analyses

L'analyse des résultats obtenus avec différentes approches d'explicabilité révèle une cohérence globale dans l'identification des variables influentes sur la classification des étudiants en Faible (L), Moyen (M) ou Élevé (H). Les élèves classés en L présentent souvent des absences fréquentes, une participation réduite en classe et une satisfaction parentale moindre, tandis que ceux classés en H sont plus engagés dans leur apprentissage et consultent davantage les ressources pédagogiques.

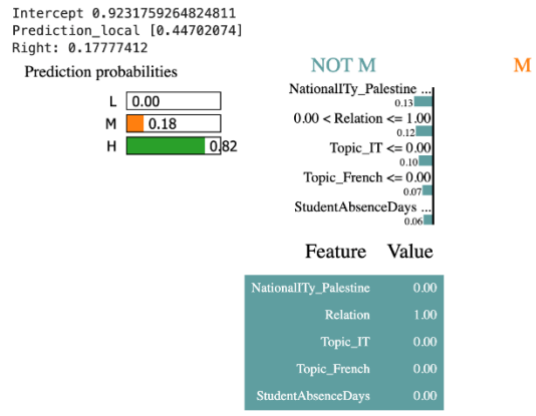


Figure 2 Explication locale d'une prédiction par LIME, illustrant les variables influençant la classification et leur impact sur la probabilité de la classe M

LIME est une méthode rapide et facile à utiliser. Cependant, lorsqu'il s'agit d'une classification à plusieurs classes, son interprétation devient plus délicate, car la diminution de la probabilité d'une classe ne signifie pas forcément que les autres sont favorisées (cf. figure 2), ce qui peut rendre les conclusions plus difficiles à exploiter. SHAP, en revanche, fournit des explications détaillées en quantifiant l'impact de chaque variable sur la prédiction. Son approche permet d'assurer une meilleure stabilité des résultats et d'offrir une vision plus précise du fonctionnement du modèle, rendant ainsi l'analyse des décisions plus fiable et interprétable.

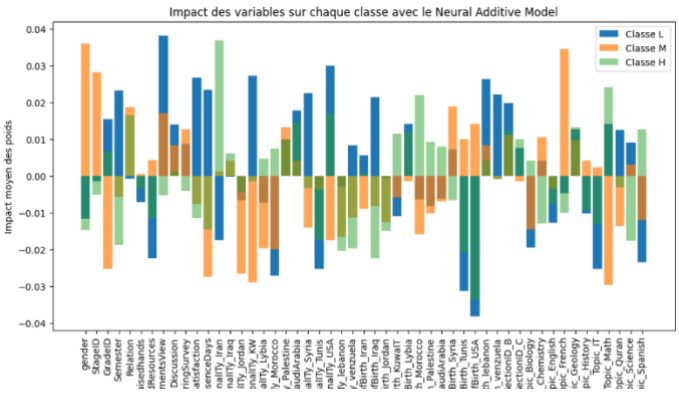


Figure 3 : Impact moyen des variables sur chaque classe avec le Neural Additive Model (NAM).

Le MLP peu profond, bien qu'interprétable grâce à l'analyse des poids des connexions, ne permet pas toujours d'isoler clairement les relations entre les variables et les prédictions. Ainsi, même si les poids des connexions donnent une idée des variables les plus importantes, ils ne permettent pas toujours d'identifier précisément comment chaque variable influence la prédiction

finale, rendant l'explication plus abstraite et moins intuitive. NAM, quant à lui, est conçu pour être intrinsèquement explicable (cf. figure 3). Il est plus stable et plus facile à interpréter car il traite chaque variable indépendamment, sans interactions complexes comme dans les réseaux de neurones classiques. Cela permet d'identifier directement l'impact de chaque caractéristique sur la prédiction, garantissant une explication plus claire et cohérente.

Critère	LIME	SHAP	MLP peu profond	NAM
Explication individuelle précise	Bonne	Très détaillée	Faible	Claire et compréhensible
Explication globale	Limitée	Complète et cohérente	Moyenne	Structurée et stable
Interprétabilité	Moyenne	Fiable et détaillée	Modérée	Transparente
Utilité pour la prise de décision	Utile mais approximative	Pertinente et robuste	Utile mais abstraite	Directement exploitable
Facilité d'implémentation	Simple et rapide	Simple	Moyenne	Nécessite des ajustements
Robustesse des explications	Sensible aux variations	Stable et fiable	Variable	Stable et cohérente

Figure 4 : Comparaison des méthodes d'explicabilité selon plusieurs critères

À l'issue de ce travail, nous avons conclu qu'il n'existe donc pas de méthode parfaite mais que tout dépend des objectifs et des contraintes du projet. Les méthodes post-hoc telles que LIME, SHAP, LRP, XRAI sont particulièrement utiles lorsqu'on souhaite expliquer un modèle de réseau de neurones déjà entraîné, sans avoir à modifier son architecture. À l'inverse, les approches intrinsèquement explicables intègrent directement l'interprétabilité dans la conception du modèle, rendant les décisions plus transparentes, mais moins performante dans certains cas.

Il est aussi envisageable de combiner une méthode post-hoc avec un modèle explicable afin de compenser les limites de chacune et d'obtenir un équilibre entre interprétabilité et performance.

Défis et lacunes des travaux existants

Malgré les avancées en intelligence artificielle explicable (XAI), plusieurs défis persistent, rendant l'évaluation et l'application de ces méthodes complexes. Une première difficulté réside dans la fragmentation des recherches : la majorité des travaux se concentrent sur une approche spécifique, rendant difficile une comparaison exhaustive des méthodes. Certaines techniques, comme LIME et SHAP, ont fait l'objet d'études approfondies, tandis que d'autres, comme la méthode WACH, restent peu documentées, ce qui limite leur compréhension et leur adoption à grande échelle.

Un autre obstacle majeur concerne l'absence d'un cadre unifié permettant d'évaluer objectivement l'efficacité des différentes approches d'explicabilité. L'explicabilité reste un concept subjectif, et les critères utilisés pour valider ces méthodes ne sont pas universelle.

De plus, l'un des dilemmes fondamentaux en XAI réside dans le compromis entre interprétabilité et performance. Les approches post-hoc permettent d'expliquer des modèles puissants sans en modifier l'architecture, mais elles n'assurent pas nécessairement une fidélité totale au processus décisionnel réel du modèle. À l'inverse, les modèles intrinsèquement explicables, bien que conçus pour être interprétables dès leur construction, imposent souvent des contraintes structurelles qui peuvent affecter leur performance. Cette tension entre transparence et efficacité soulève des questions fondamentales sur l'optimisation des modèles XAI pour différents contextes d'application.

Nous pouvons aussi constater qu'un autre enjeu clé concerne l'accessibilité des méthodes XAI aux utilisateurs finaux. Bien que les outils d'explicabilité aient été développés pour renforcer la transparence

des modèles d'IA, leur complexité technique reste un frein majeur à leur adoption. De nombreuses méthodes requièrent une expertise avancée. Il est donc essentiel de développer des interfaces et des représentations simplifiées permettant aux non-experts d'interagir avec ces systèmes de manière intuitive.

Dans l'ensemble, l'intelligence artificielle explicable est un domaine en constante évolution, où de nombreux défis restent à relever. La mise en place de cadres d'évaluation standardisés, l'amélioration de l'explicabilité des modèles de réseaux de neurone, ainsi que la démocratisation des outils XAI constituent des axes de recherche majeurs pour les années à venir.

Perspectives

Ce travail met en évidence le défi fondamental de l'explicabilité en intelligence artificielle : trouver un compromis entre performance et interprétabilité des modèles de réseaux de neurones. Aucune approche ne constitue une solution universelle, et chaque méthode présente des avantages et des limites selon le contexte d'application.

Une première perspective de recherche serait éventuellement d'explorer les architectures hybrides, combinant des modèles intrinsèquement explicables avec des méthodes post-hoc. L'objectif serait d'évaluer la complémentarité entre ces approches, afin d'optimiser à la fois la robustesse des explications et la performance du modèle. Une telle démarche permettrait de contourner les limites des modèles purement post-hoc, tout en conservant la flexibilité des réseaux neuronaux classiques.

Un autre axe prometteur consiste à approfondir l'exploration des méthodes d'optimisation automatique, en particulier celles reposant sur la neuro-évolution. L'objectif serait de générer des architectures de réseaux de neurones optimisées à la fois pour la précision et l'explicabilité, plutôt que de sélectionner manuellement la structure du modèle. Ces techniques permettraient d'explorer dynamiquement différentes configurations et d'identifier celles qui offrent le meilleur compromis entre performance et transparence.

De surcroit, une autre dimension a amélioré concerne l'accessibilité des méthodes XAI aux utilisateurs non-experts. Les résultats obtenus montrent que les outils d'explicabilité actuels restent souvent complexes à interpréter pour des non-spécialistes. Actuellement, de nombreuses méthodes d'explicabilité nécessitent un haut niveau d'expertise technique, limitant leur utilisation aux spécialistes en apprentissage automatique. Il serait essentiel de concevoir des interfaces interactives et des visualisations pédagogiques permettant aux utilisateurs non experts de mieux comprendre les décisions des modèles. L'intégration d'explications générées en langage naturel ou de schémas interactifs pourrait favoriser une adoption plus large des systèmes XAI, notamment dans des domaines tels que la médecine, la finance ou la prise de décision automatisée.

Dans l'ensemble, l'intelligence artificielle explicable reste un domaine de recherche en pleine évolution. L'avenir de cette discipline repose sur le développement de modèles plus robustes et interprétables, tout en garantissant une meilleure accessibilité des outils d'explicabilité pour une meilleure transparence des décisions algorithmiques.

References

[1] Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2017). *ImageNet Classification with Deep Convolutional Neural Networks*. Communications of the ACM, 60(6), 84–90.

[2] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). *Attention Is All You Need*. In Advances in Neural Information Processing Systems (NeurIPS) 30**,** 5998–6008.

[3] Sezer, O. B., Gudelek, M. U., & Ozbayoglu, A. M. (2020). *Financial Time Series Forecasting with Deep Learning: A Systematic Literature Review: 2005–2019*. Applied Soft Computing, 90, 106181.

[4] Rudin, C. (2019), *Stop Explaining Black Box Machine Learning Models for High Stakes Decisions and Use Interpretable Models Instead*. Nature Machine Intelligence**,** 1(5), 206–215.

[5] European Parliament and Council (2016), *Regulation (EU) 2016/679 of 27 April 2016 on the Protection of Natural Persons with Regard to the Processing of Personal Data and on the Free Movement of Such Data (General Data Protection Regulation)*. Official Journal of the European Union, L 119, 4 May 2016, pp. 1–88.

[6] European Commission. (2021), *Proposal for a Regulation of the European Parliament and of the Council Laying Down Harmonised Rules on Artificial Intelligence (Artificial Intelligence Act) and Amending Certain Union Legislative Acts (COM(2021) 206 final)*

[7] Adadi, A., & Berrada, M. (2018). *Peeking Inside the Black-Box: A Survey on Explainable Artificial Intelligence (XAI)*. IEEE Access, 6, 52138–52160.

[8] Guidotti, R., Monreale, A., Turini, F., Pedreschi, D., & Giannotti, F. (2019). *A Survey of Methods for Explaining Black Box Models*. ACM Computing Surveys (CSUR)**,** 51(5), 93:1–93:42.

[9] Zawacki-Richter, O., Marin, V. I., Bond, M., & Gouverneur, F. (2019). *Systematic Review of Research on Artificial Intelligence Applications in Higher Education – Are the Technologies Developed Fit for Purpose?* International Journal of Educational Technology in Higher Education**,** 16(1), 1–27.

[10] Holstein, A., Wortman, P., & Aleven, V. (2022). *Trusting the Explainers: Teacher Validation of Explainable Artificial Intelligence for Course Design* [Preprint]. arXiv:2212.08955

[11] Doshi-Velez, F., & Kim, B. (2017). *Towards A Rigorous Science of Interpretable Machine Learning* [Preprint]. arXiv:1702.08608

[12] Lipton, Z. C. (2018). *The Mythos of Model Interpretability*. Queue, 16(3), 31–57.

[13] Serafini, L., & d'Avila Garcez, A. (2016). *Logic Tensor Networks: Deep Learning and Logical Reasoning from Data and Knowledge.* In Proceedings of the 10th International Workshop on Neural-Symbolic Learning and Reasoning (NeSy).

[14] Lundberg, S. M., & Lee, S.-I. (2017). *A Unified Approach to Interpreting Model Predictions*. In Advances in Neural Information Processing Systems (NeurIPS)**,** 4765–4774.

[15] Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). *"unihould I Trust You?" Explaining the Predictions of Any Classifier*. In Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 1135–1144.

[16] Erion, G., Janizek, J. D., Sturmfels, P., Lundberg, S. M., & Lee, S.-I. (2021). *Improving Performance of Deep Learning Models with Axiomatic Attribution Priors and Expected Gradients*. Nature Machine Intelligence, 3(7), 489–499.

[17] Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., & Batra, D. (2017). *Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization*. In Proceedings of the IEEE International Conference on Computer Vision (ICCV)**,** 618–626.

[18] Bach, S., Binder, A., Montavon, G., Klauschen, F., Müller, K. R., & Samek, W. (2015). *On Pixel-Wise Explanations for Non-Linear Classifier Decisions by Layer-Wise Relevance Propagation*. PLoS ONE, 10(7), e0130140.

[19] Kapishnikov, A., Bolukbasi, T., Viegas, F., & Terry, M. (2019). *XRAI: Better Attributions Through Regions*. In Proceedings of the 2019 IEEE/CVF International Conference on Computer Vision (ICCV)**,** 4947–4956.

[20] Petsiuk, V., Das, A., & Saenko, K. (2018). *RISE: Randomized Input Sampling for Explanation of Black-box Models*. In Proceedings of the British Machine Vision Conference (BMVC)**,** 151.

[21] Stumpf, S., Rajaram, V., Li, L., Burnett, M., Dietterich, T., & Sullivan, E. (2009). *Interacting Meaningfully with Machine Learning Systems: Three Experiments*. International Journal of Human-Computer Studies, 67(8), 639–662.

[22] Ribeiro, M. T., Singh, S., & Guestrin, C. (2018). *Anchors: High-Precision Model-Agnostic Explanations*. In AAAI (Vol. 32, No. 1)**.**

[23] Joo, S., Jeong, S., Heo, J., Weller, A., & Moon, T. (2022). *Towards More Robust Interpretation via Local Gradient Alignment.* In *Proceedings of the AAAI Conference on Artificial Intelligence* (Vol. 37, No. 7)

[24] Samek, W., Montavon, G., Lapuschkin, S., Anders, C. J., & Müller, K.-R. (2021). *Explaining Deep Neural Networks and Beyond: A Review of Methods and Applications in Different Fields*. In IEEE Signal Processing Magazine, 38(6), 72–87.

[25] A. Wan, L. Dunlap, R. L. Grosse, B. Balle, and P. J. Ramadge, *NBDT: Neural-Backed Decision Trees,* [Preprint] arXiv:2004.00221, 2020. doi: 10.48550/arXiv.2004.00221.

[26] R. Caruana, Understanding Neural Networks with Model Compression, in *Proceedings of the Twenty-first International Conference on Machine Learning (ICML)*, 2004, pp. 354–361.

[27] P. W. Koh and P. Liang, *Understanding Black-box Predictions via Influence Functions*, in Proceedings of the 37th International Conference on Machine Learning (ICML)*,* 2020, pp. 5495–5505.

[28] A. Alvarez-Melis and T. S. Jaakkola, *Towards Robust Interpretability with Self-Explaining Neural Networks*, in Advances in Neural Information Processing Systems (NeurIPS), 2018, pp. 7786-7795.

[29] P. B. Costa, G. Marques, A. C. Serra, D. S. Moraes, A. J. G. Busson, Á. L. V. Guedes, G. Lima, and S. Colcher, *Towards Neural-Symbolic AI for Media Understanding*, in Anais Estendidos do WebMedia'2020*,* São Luís, Brasil, 2020. DOI: 10.5753/webmedia_estendido.2020.13083.

[30] Manhaeve, R., Dumančić, S., Kimmig, A., Demeester, T., & De Raedt, L. (2018). *DeepProbLog: Neural Probabilistic Logic Programming* [Preprint]. arXiv:1805.10872.

Autres travaux

Il existe des travails similaires, que nous n'avons pas eu le temps de prendre connaissance.

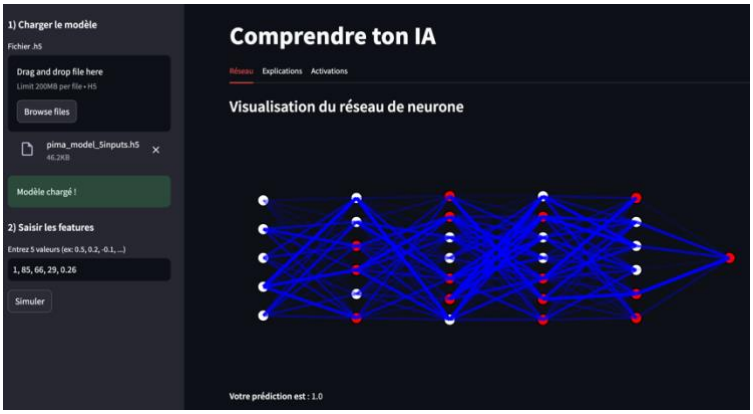
[31] Narkhede, J., 2024, *Comparative Evaluation of Post-Hoc Explainability Methods in AI: LIME, SHAP, and Grad-CAM*, In 2024 4th International Conference on Sustainable Expert Systems (ICSES) (pp. 826-830). IEEE.

[32] A. N. Other, B. Researcher, and C. Scholar, *Problems with SHAP and LIME in interpretable AI for education: A comparative study of post-hoc explanations and neural-symbolic rule extraction*, 2024.

Annexe

Lien du git où l'on peut retrouver le code réaliser durant la réalisation de ce papier de recherche à savoir l'interface graphique et l'expérience réalisé: https://forge.univ-lyon1.fr/p1805862/xai.git

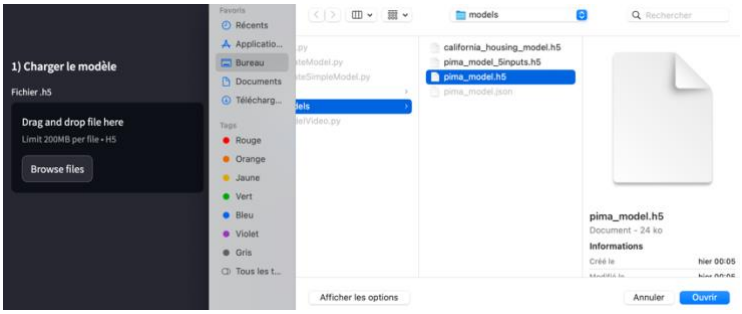
Interface graphique



Visualisation de l'architecture d'un réseau de neurones passé en entrer.

Les connexions entre les neurones sont représentées de manière à ce que leur épaisseur et leur intensité de couleur reflètent la valeur de leur poids.

Montre la fenêtre d'import du modèle .h5., permettant à l'utilisateur de charger dynamiquement un réseau de neurones où une fois le fichier chargé, l'interface met immédiatement à jour la visualisation et les fonctionnalités associées.





Cette capture illustre l'onglet « Explications » de l'interface, où l'utilisateur peut choisir la méthode d'interprétation (SHAP ou LIME) et visualiser la contribution de chaque variable dans la prédiction. Ici, il s'agit de la méthode SHAP avec les barres rouges et bleues mettent en évidence l'influence positive ou négative de chaque feature sur le résultat final.

Ici, nous avons l'onglet « Activations », dans lequel nous retrouvons des heatmaps représentant l'activation de chaque neurone dans les différentes couches du réseau. Nous pouvons aussi retrouver cette information dans la visualisation de l'architecture du réseau de neurone avec les neurones activés en rouge.



Expérience de notre recherche

Voir le notebook présent à la racine du lien GitHub plus haut.